Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ Информатика и системы управления

КАФЕДРА Системы обработки информации и управления

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА

К КУРСОВОЙ РАБОТЕ

НА ТЕМУ:

решение комплексной задачи машинного обучения

Студент ИУ5-63Б — **Кривцов Н.А.**
(Группа) (Подпись, дата) (И.О.Фамилия)

Руководитель курсовой работы — **Гапанюк Ю.Е.**
(Подпись, дата) (И.О.Фамилия)

Консультант
(Подпись, дата) (И.О.Фамилия)

2020 г.

Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

УТВЕРЖДАЮ
Заведующий кафедрой _____
(Индекс)
_____ _____
(И.О.Фамилия)
« _____ » _____ 20 ____ г.

ЗАДАНИЕ
на выполнение курсовой работы

по дисциплине _____Технологии машинного обучения_____

Студент группы ___ИУ5-63Б___

_____Кривцов Никита Александрович_____
(Фамилия, имя, отчество)

Тема курсовой работы _____решение комплексной задачи машинного обучения_____
_____
_____

Направленность КР (учебная, исследовательская, практическая, производственная, др.)
_____учебная_____
Источник тематики (кафедра, предприятие, НИР) _____кафедра_____

График выполнения работы: 25% к ___ нед., 50% к ___ нед., 75% к __ нед., 100% к ___ нед.

Задание ____разработать модели машинного обучения, решающие задачу классификации__ или регрессии_____
_____

Оформление курсовой работы:

Расчетно-пояснительная записка на _____ листах формата А4.
_____
_____
_____
_____

Дата выдачи задания « ___ » _____ 20__ г.

Руководитель курсовой работы _____ ___**Гапанюк Ю.Е**.___
(Подпись, дата) (И.О.Фамилия)

Студент _____ ___**Кривцов Н.А.**___
(Подпись, дата) (И.О.Фамилия)

Примечание: Задание оформляется в двух экземплярах: один выдается студенту, второй хранится на кафедре.

1. Поиск и выбор набора данных для построения моделей машинного обучения

В работе будет использоваться набор данных о музыкальных композициях, размещённых на музыкальном стриминговом сервисе Spotify. Датасет был взят с веб-портала Kaggle. Дополнительную информацию о наборе данных можно найти по ссылке.

Целью работы с такими данными является прогнозирование популярности той или иной композиции, что может быть выгодно как её авторам и исполнителям, так и лейбл-компаниям, её выпустившим.

Предложенный по ссылке выше датасет состоит из нескольких файлов:

- data.csv
- data_by_artist.csv
- data_by_genres.csv
- data_by_year.csv
- data_w_genres.csv
- super_genres.json

В рамках настоящей работы будет использоваться только файл data.csv. Признаки, представленные в файле:

- acousticness - мера акустического звучания композиции
- artists - исполнители
- danceability -
- duration_ms - продолжительность композиции в миллисекундах
- energy -
- explicit - наличие нецензурной лексики в словах песни
- instrumentalness -
- key
- liveness -
- loudness -
- mode -
- name - название композиции
- popularity - мера популярности композиции **(целевой признак)**
- release_date - дата релиза композиции
- speechiness
- tempo - темп композиции в bpm (beats per minute / удары в минуту)
- valence
- year - год релиза композиции

На решение выставляется задача **регрессии** по целевому признаку `popularity`.

[0]:
```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
```

```
/usr/local/lib/python3.6/dist-packages/statsmodels/tools/_testing.py:19:
FutureWarning: pandas.util.testing is deprecated. Use the functions in
  ↪the
public API at pandas.testing instead.
  import pandas.util.testing as tm
```

1.1. Загрузка данных

Данные из датасаета загружаются с применением библиотеки Pandas. Метод `pd.read_csv()` считывает данные из файла data.csv, представляющего собой набор табличных записей, где столбцы отделены друг от друга запятыми (comma-separated values), и сохраняет их в объект `df` класса `pd.Dataframe`.

[0]:
```
# Признаки "Unnamed: 0" и "id" удаляются за ненадобностью
df = pd.read_csv("/content/drive/My Drive/Colab Notebooks/data.csv").
↪drop(["Unnamed: 0", "id"], axis=1)
```

2. Разведочный анализ данных

2.1. Основные характеристики датасета

[0]:
```
# Список признаков
df.columns
```

[0]:
```
Index(['acousticness', 'artists', 'danceability', 'duration_ms',
↪'energy',
       'explicit', 'instrumentalness', 'key', 'liveness', 'loudness',
↪'mode',
       'name', 'popularity', 'release_date', 'speechiness', 'tempo',
↪'valence',
       'year'],
      dtype='object')
```

[0]:
```
# Типы признаков
df.dtypes
```

[0]:
```
acousticness        float64
artists              object
danceability        float64
duration_ms           int64
energy              float64
explicit              int64
instrumentalness    float64
key                   int64
liveness            float64
loudness            float64
mode                  int64
name                 object
popularity            int64
release_date         object
speechiness         float64
tempo               float64
valence             float64
year                  int64
dtype: object
```

Целевой признак `popularity` обладает типом `int64`, что усложняет задачу регрессии по нему. Возникает необходимость преобразования его в `float64`.

Помимо численных, в наборе присутствуют три категориальных признака типа `object`. По существу, признак `key` тоже является категориальным, т.к. он определяет музыкальную тональность композиции. Тем не менее, этот признак был преобразован создателем датасета в целочисленный методом **Label Encoding**. Неявное задание отношения порядка на этом признаке не является неособованным - музыкальные тональности, в общем случае, упорядочены по возрастанию “высоты” звука, т.е. использование этого кодирования вполне уместно.

[0]:
```
# Проверка на наличие пропусков
df.isnull().sum()
```

[0]:
```
acousticness        0
artists             0
danceability        0
duration_ms         0
energy              0
explicit            0
instrumentalness    0
key                 0
liveness            0
loudness            0
mode                0
name                0
popularity          0
release_date        0
speechiness         0
tempo               0
valence             0
year                0
dtype: int64
```

В данных отсутствуют пропуски!

[0]:
```
# Первые 5 записей
df.head()
```

[0]:
```
   acousticness  …  year
0         0.732  …  1921
1         0.982  …  1921
2         0.996  …  1921
3         0.982  …  1921
4         0.957  …  1921

[5 rows x 18 columns]
```

Для всех численных признаков построим диаграммы распределения и графики `violinplot`. (Примечание: метод `sns.pairplot()` библиотеки Seaborn не применяется ввиду слишком большого объёма данных, необходимых для отрисовки как графиков распределений, так и графиков попарных зависемостей признаков.)

[0]:
```
for numeric_column in df.select_dtypes(include=np.number):
  sns.distplot(df[numeric_column])
```

```
plt.show()
```

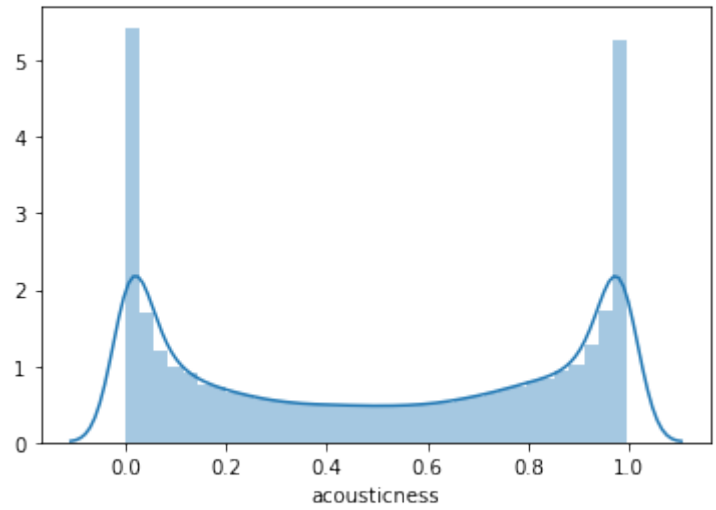
0
1
2
3
4
5
0.0
0.2
0.4
0.6
0.8
1.0
acousticness

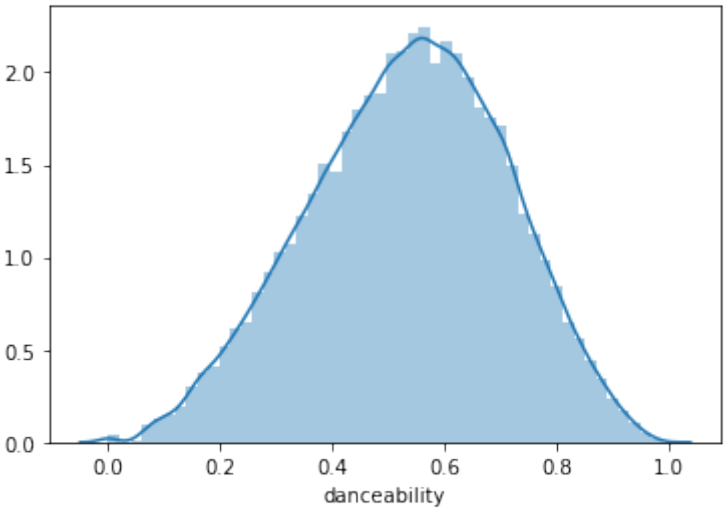
0.0
0.5
1.0
1.5
2.0
0.0
0.2
0.4
0.6
0.8
1.0
danceability

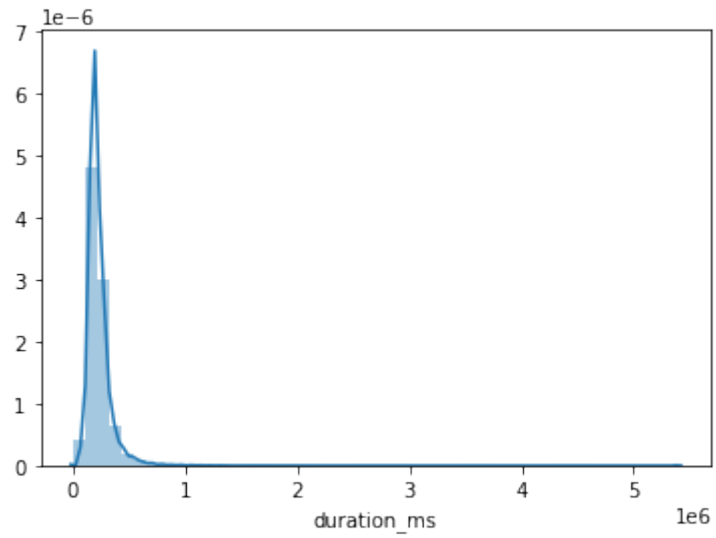
1e−6
0
1
2
3
4
5
6
7
0
1
2
3
4
5
duration_ms
1e6

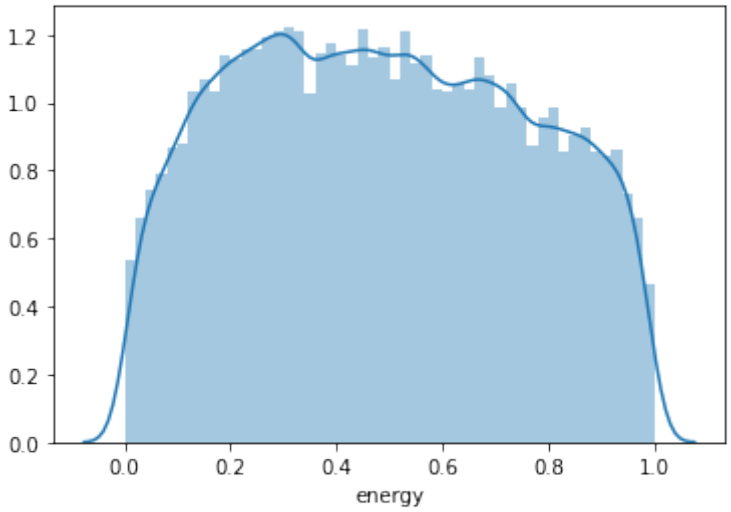
1.2
1.0
0.8
0.6
0.4
0.2
0.0
0.0
0.2
0.4
0.6
0.8
1.0
energy

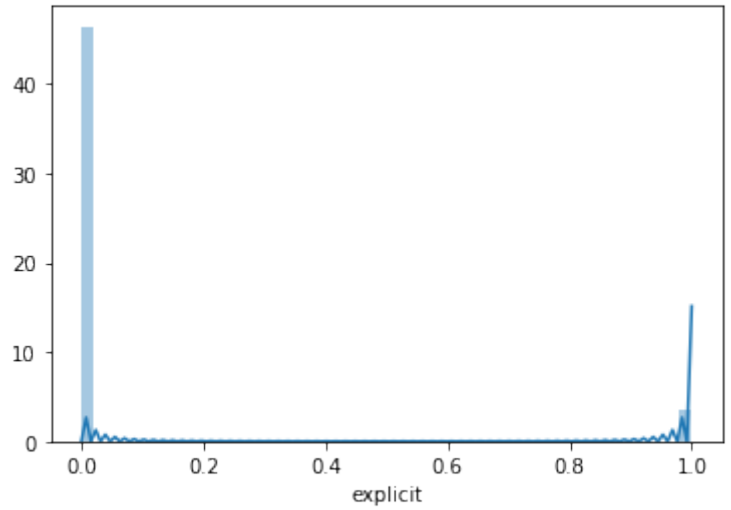
40
30
20
10
0
0.0
0.2
0.4
0.6
0.8
1.0
explicit

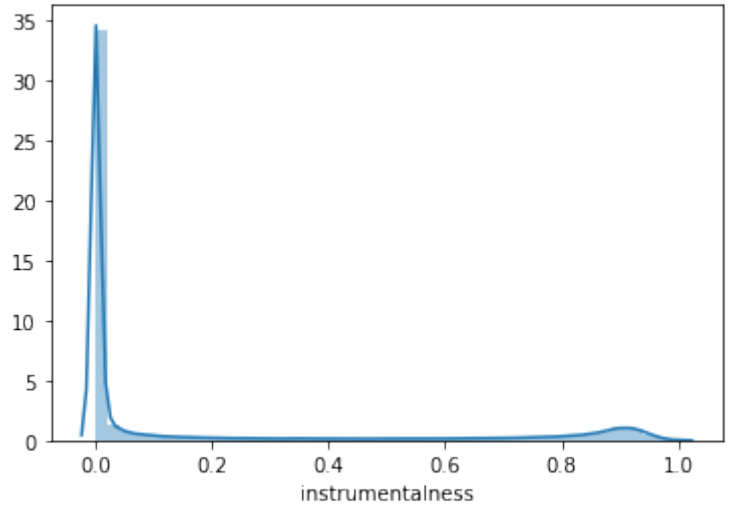
35
30
25
20
15
10
5
0
0.0
0.2
0.4
0.6
0.8
1.0
instrumentalness

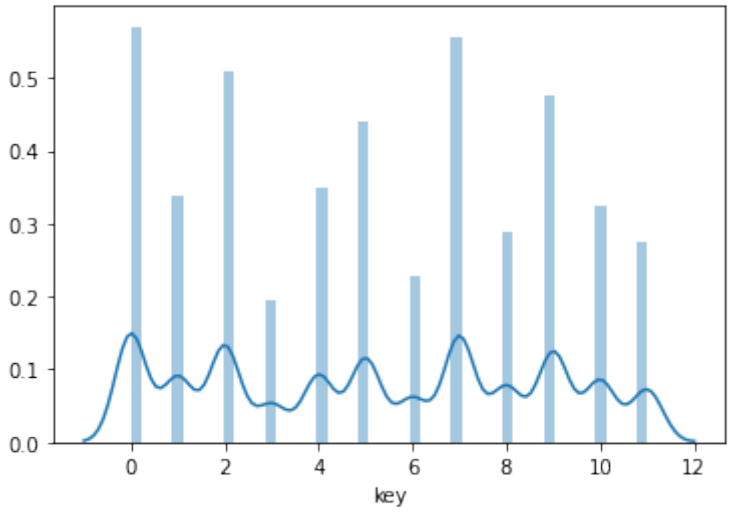
0.5
0.4
0.3
0.2
0.1
0.0
0
2
4
6
8
10
12
key

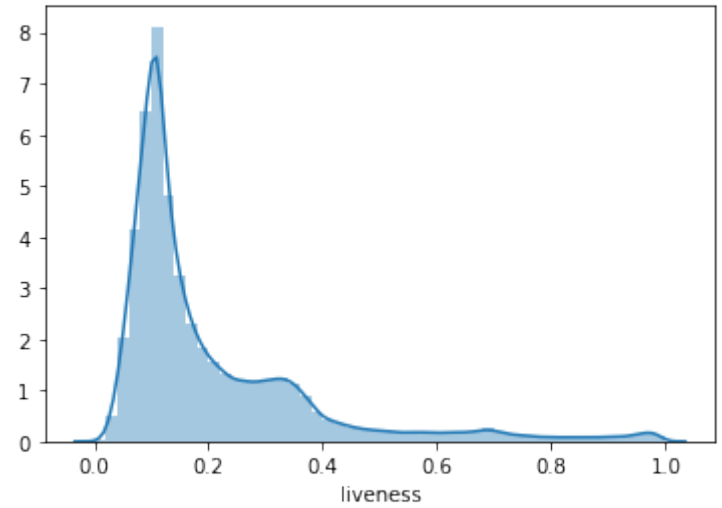
8
7
6
5
4
3
2
1
0
0.0
0.2
0.4
0.6
0.8
1.0
liveness

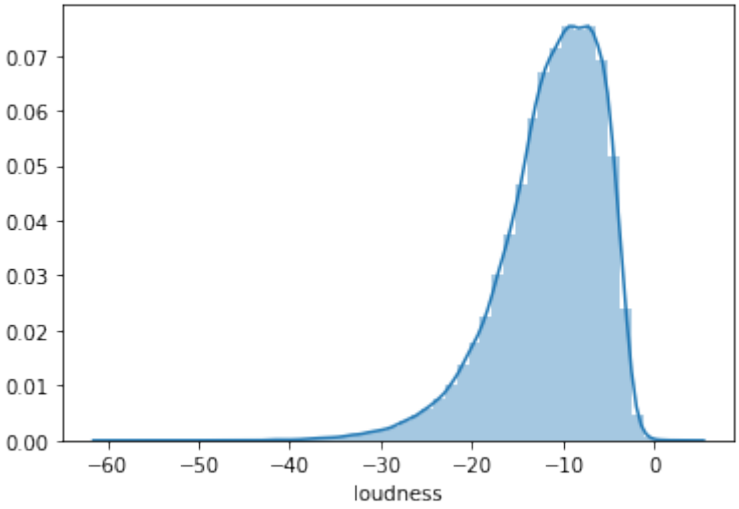
0.07
0.06
0.05
0.04
0.03
0.02
0.01
0.00
−60
−50
−40
−30
−20
−10
0
loudness

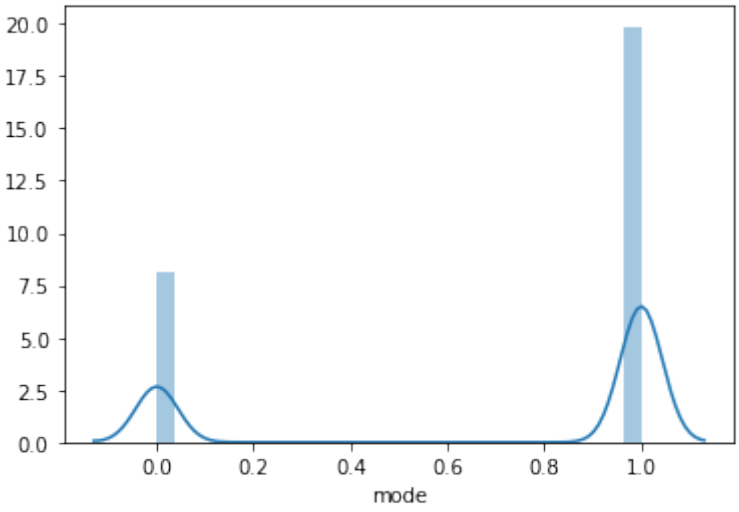
20.0
17.5
15.0
12.5
10.0
7.5
5.0
2.5
0.0
0.0
0.2
0.4
0.6
0.8
1.0
mode

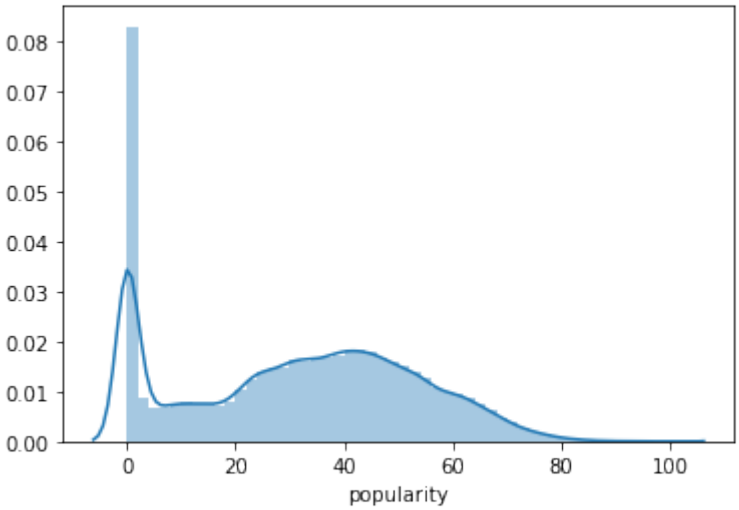
0.08
0.07
0.06
0.05
0.04
0.03
0.02
0.01
0.00
0
20
40
60
80
100
popularity

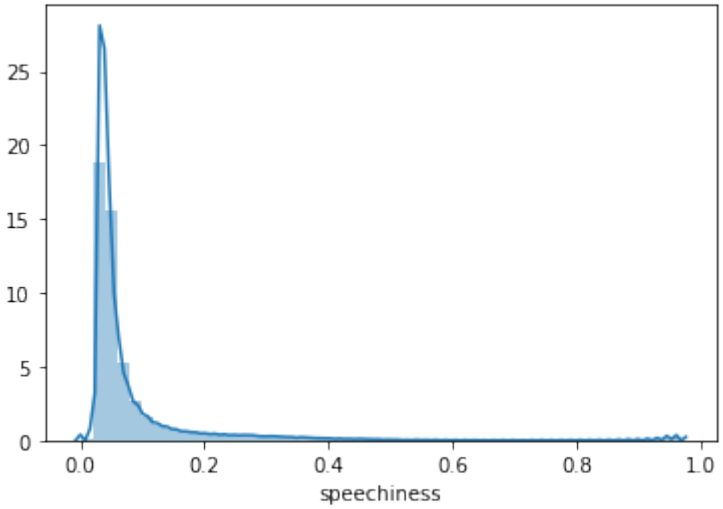
25
20
15
10
5
0
0.0
0.2
0.4
0.6
0.8
1.0
speechiness

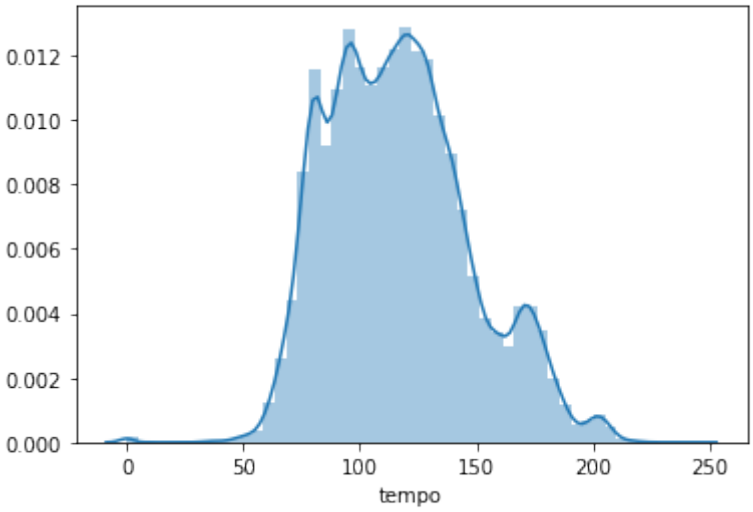
0.012
0.010
0.008
0.006
0.004
0.002
0.000
0
50
100
150
200
250
tempo

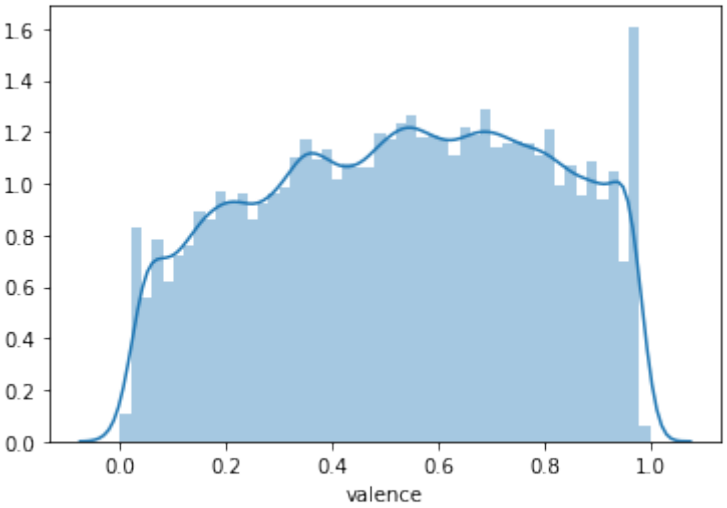
1.6
1.4
1.2
1.0
0.8
0.6
0.4
0.2
0.0
0.0
0.2
0.4
0.6
0.8
1.0
valence

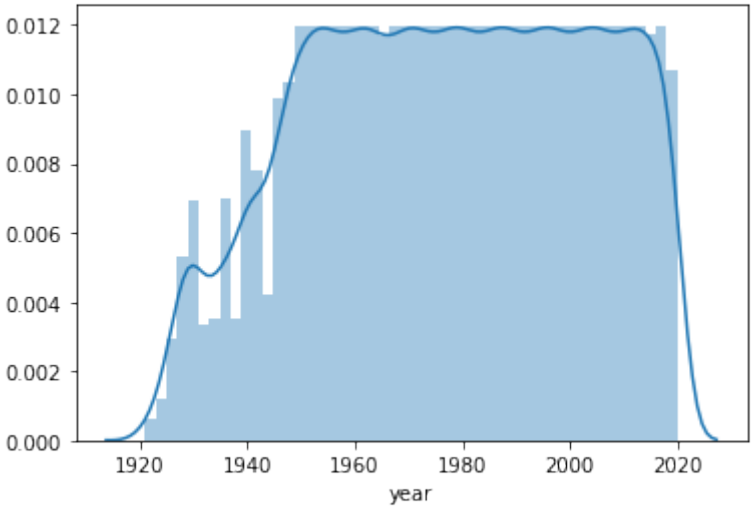
0.012
0.010
0.008
0.006
0.004
0.002
0.000
1920
1940
1960
1980
2000
2020
year

[0]:
```
for numeric_column in df.select_dtypes(include=np.number):
  sns.violinplot(df[numeric_column])
  plt.show()
```

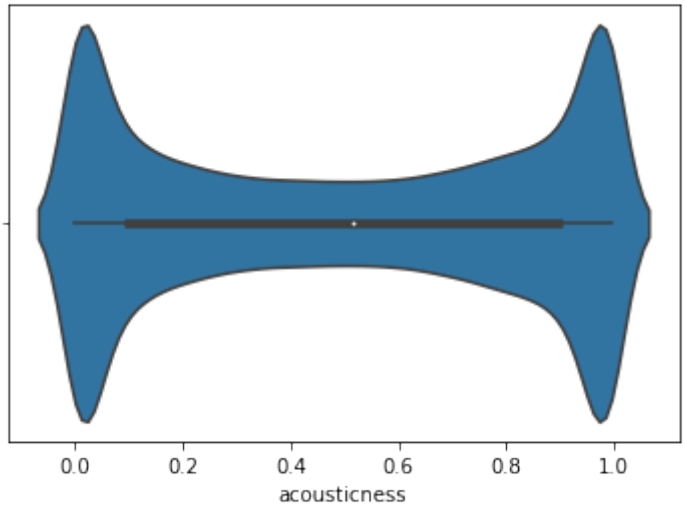

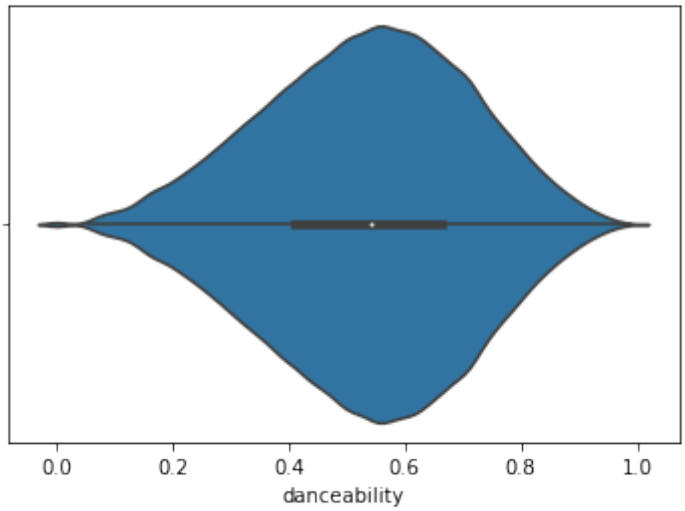

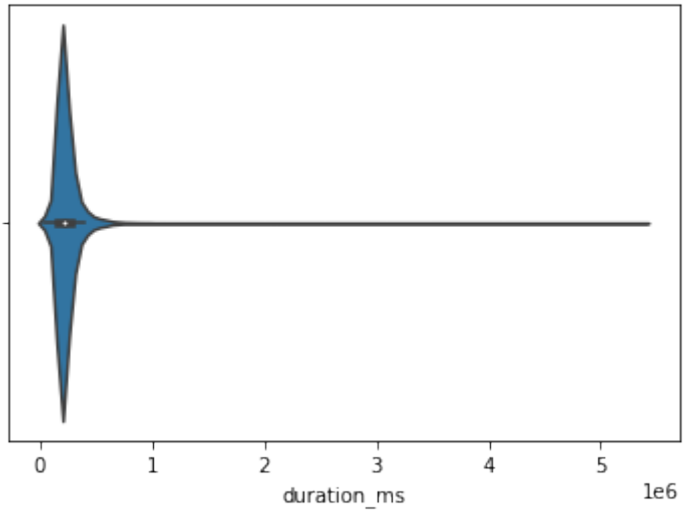
0
1
2
3
4
5
duration_ms
1e6

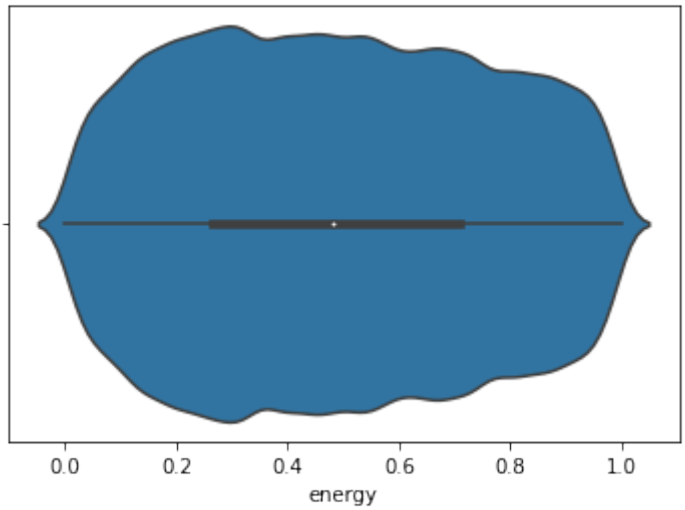
0.0
0.2
0.4
0.6
0.8
1.0
energy

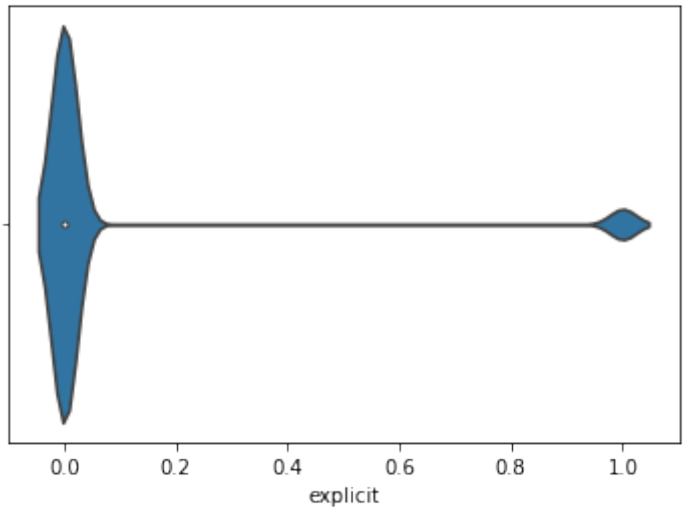
0.0
0.2
0.4
0.6
0.8
1.0
explicit

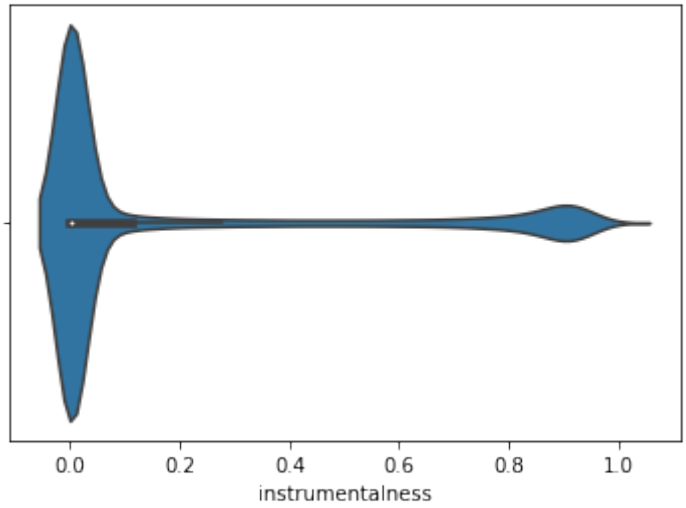
0.0
0.2
0.4
0.6
0.8
1.0
instrumentalness

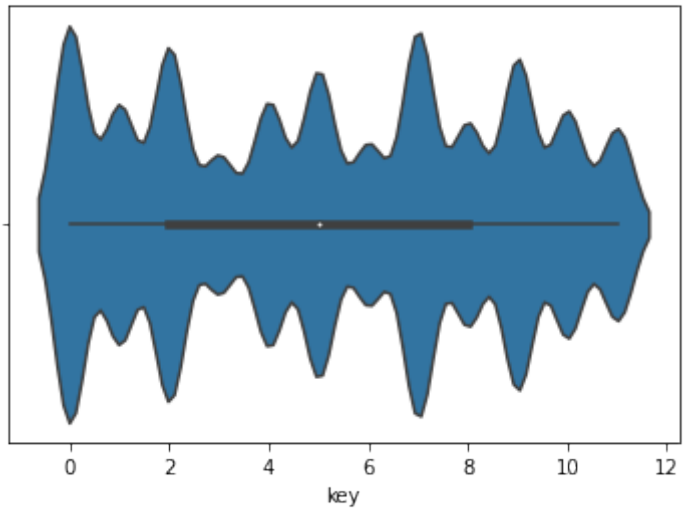
0
2
4
6
8
10
12
key

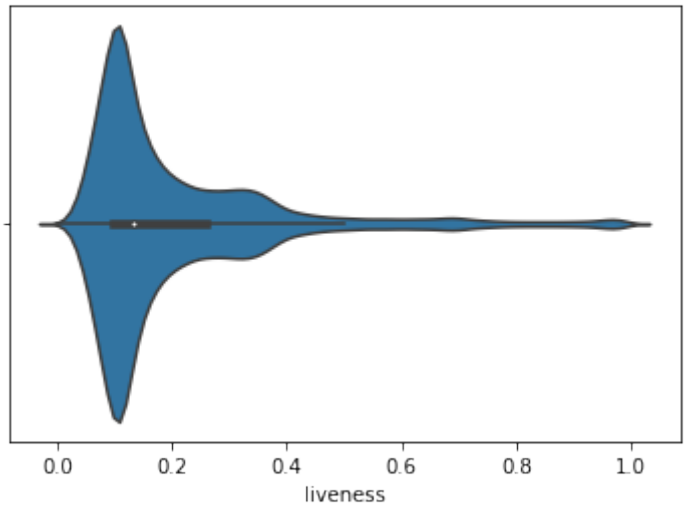
0.0
0.2
0.4
0.6
0.8
1.0
liveness

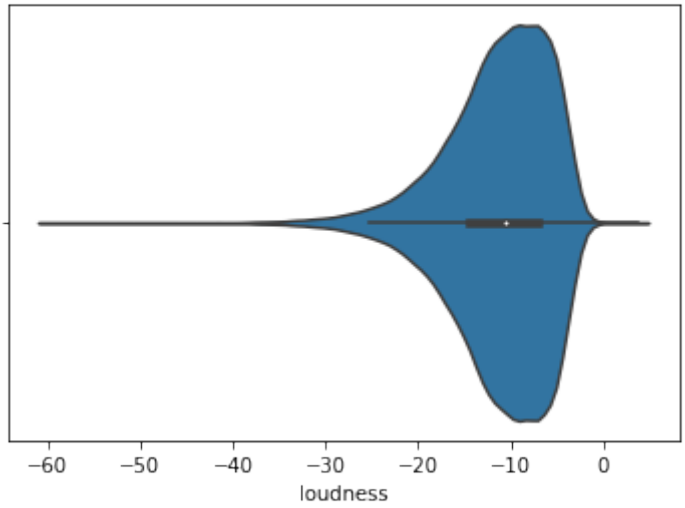
−60
−50
−40
−30
−20
−10
0
loudness

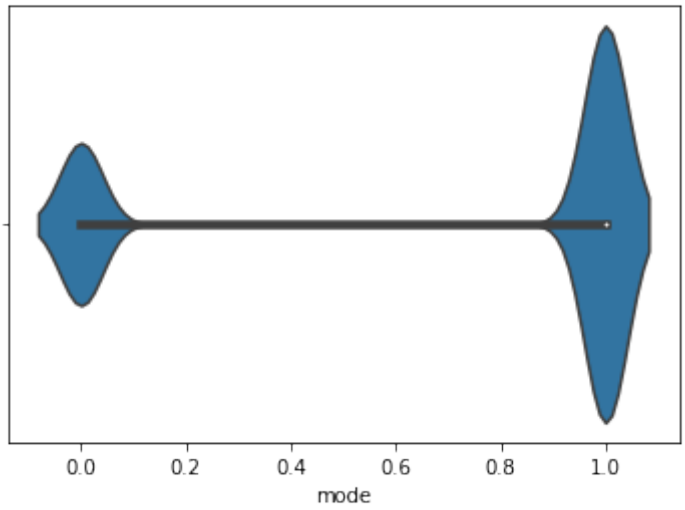
0.0
0.2
0.4
0.6
0.8
1.0
mode

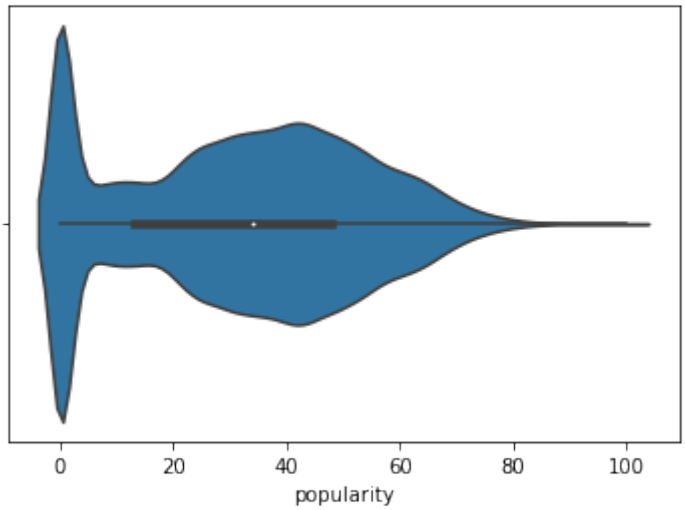
0
20
40
60
80
100
popularity

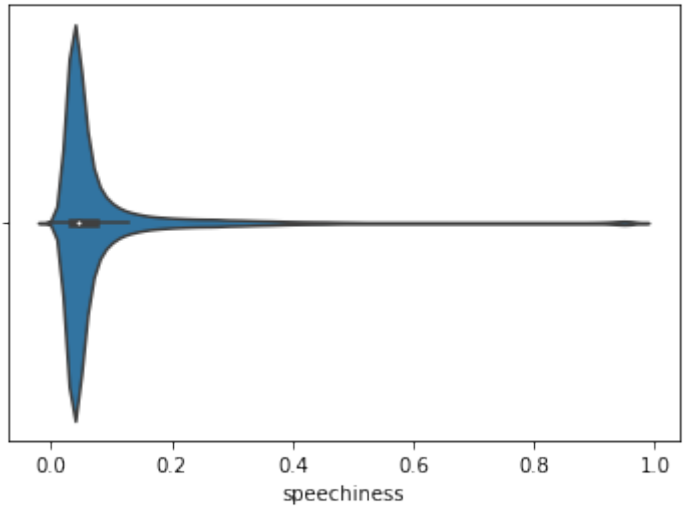
0.0
0.2
0.4
0.6
0.8
1.0
speechiness

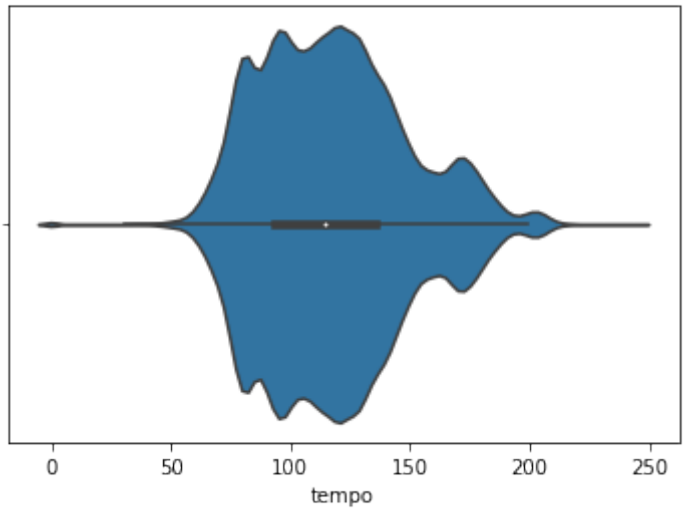
0
50
100
150
200
250
tempo

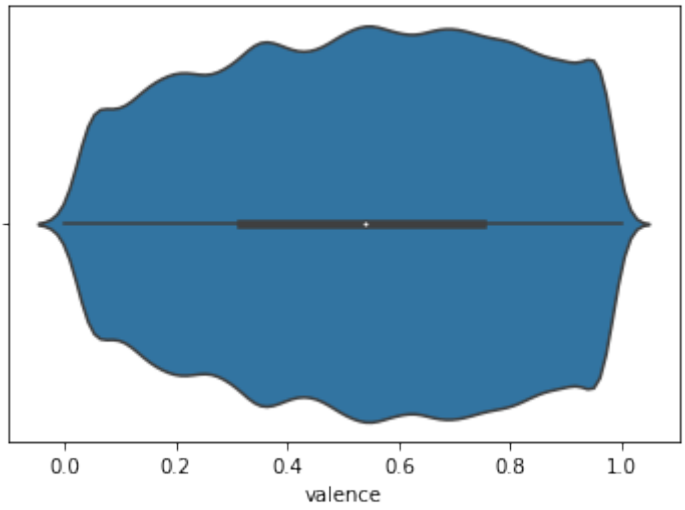
0.0
0.2
0.4
0.6
0.8
1.0
valence

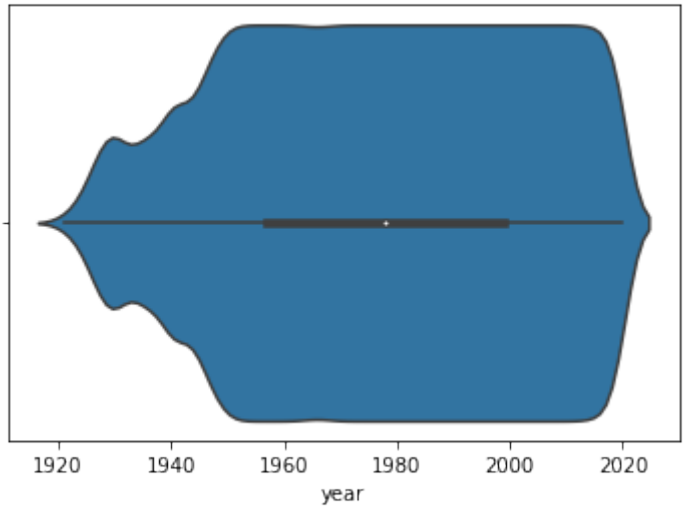

Значения признаков `acousticness`, `danceability`, `energy`, `instrumentalness`, `liveness`, `speechiness` и `valence` лежат на отрезке $[0, 1]$. Будет целесообразным привести остальные непреревные численные признаки к этому виду.

Признаки `explicit` и `mode` принимают только значения из множества $\{0, 1\}$.

3. Выбор признаков для построения моделей машинного обучения. Масштабирование целочисленных признаков

3.1. Выбор признаков

В первую очередь рассмотрим категориальные признаки. Определим количество уникальных значений каждого из них.

[0]:
```
for f in df.select_dtypes(include="object"):
  print("Число уникальных значений {}: {}.".format(f, len(df[f].
 ↪unique())))
```

```
Число уникальных значений artists: 33268.
Число уникальных значений name: 131361.
Число уникальных значений release_date: 10813.
```

Ни один из имеющихся категориальных признаков не пригоден для решения задачи:

1. Значения признака `artists` представляют собой ***списки*** артистов и авторов, участвовавших в создании и исполнении композиции. У этого признака более 30 тысяч уникальных значений! Для него ни в коем случае недопустимо применение кодирования по методу **OHE**, а кодирование методом **Label Enconding** приведёт к необоснованному упорядочиванию значений.
2. Аналогичные соображения справедливы и для признака `name`.
3. Признак `release_date` игнорируется, так как рассматриваемые данные не анализируются в качестве временного ряда.

Из соображений, аналогичных пункту 3, можно пренебречь признаком `year`.

[0]:
```
df1 = df.drop(["artists", "name", "release_date", "year"], axis=1)
```

3.2. Масштабирование признаков

Признаки `duration_ms`, `loudness` и `tempo` подлежает масштабированию. Т.к. остальные непрерывные признаки принимают значения, лежащие на отрезке $[0, 1]$, то будем использовать класс **`MinMaxScaler`** из библиотеки `sklearn.preprocessing`, т.е. применим **MinMax**-масштабирование.

[0]:
```
features_to_scale = ["duration_ms", "loudness", "tempo", "popularity"]
```

[0]:
```
from sklearn.preprocessing import MinMaxScaler
mm = MinMaxScaler()
```

[0]:
```
features_mm = mm.fit_transform(df1[features_to_scale])
```

[0]:
```
for i in range(len(features_to_scale)):
  feature = features_to_scale[i]
  new_feature = feature + "_MINMAX"
  df1[new_feature] = features_mm[:,i]

df1.head()
```

[0]:

	acousticness	danceability	…	tempo_MINMAX	popularity_MINMAX
0	0.732	0.819	…	0.249645	0.08
1	0.982	0.279	…	0.331655	0.05
2	0.996	0.518	…	0.271296	0.06
3	0.982	0.279	…	0.331655	0.04
4	0.957	0.418	…	0.416505	0.04

[5 rows x 18 columns]

Убедимся в том, что масштабирование не изменило вид распределений признаков.

[0]:
```
for feature in features_to_scale:
    feature_mm = feature + "_MINMAX"

    fig, ax = plt.subplots(1, 2, figsize=(12.8, 4.8))
    sns.distplot(df1[feature], ax=ax[0])
    sns.distplot(df1[feature_mm], ax=ax[1])
    plt.show()
```

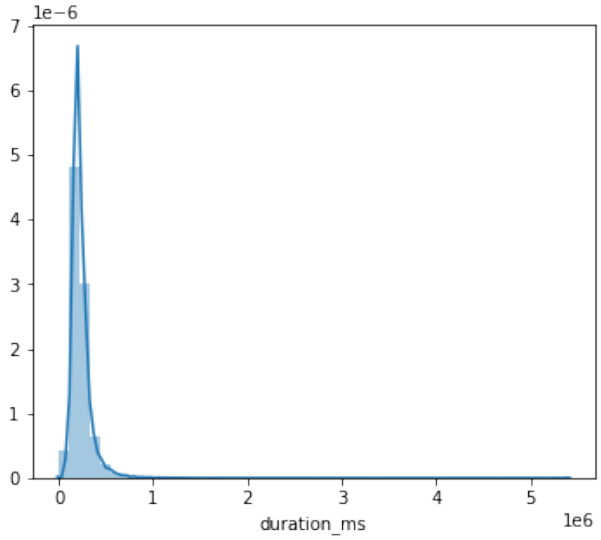
1e−6
7
6
5
4
3
2
1
0
0
1
2
3
4
5
1e6
duration_ms

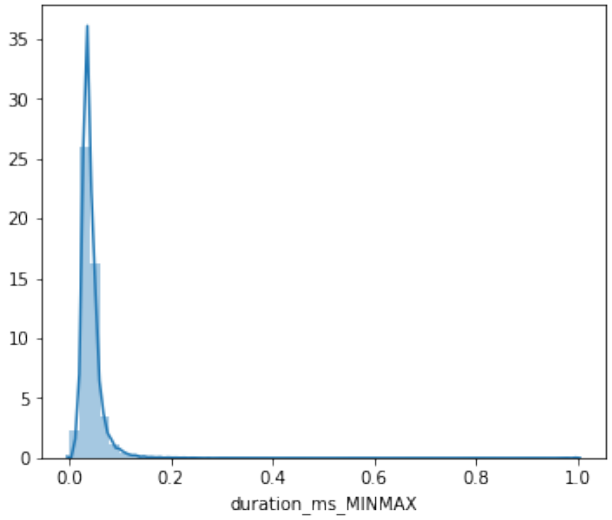
35
30
25
20
15
10
5
0
0.0
0.2
0.4
0.6
0.8
1.0
duration_ms_MINMAX

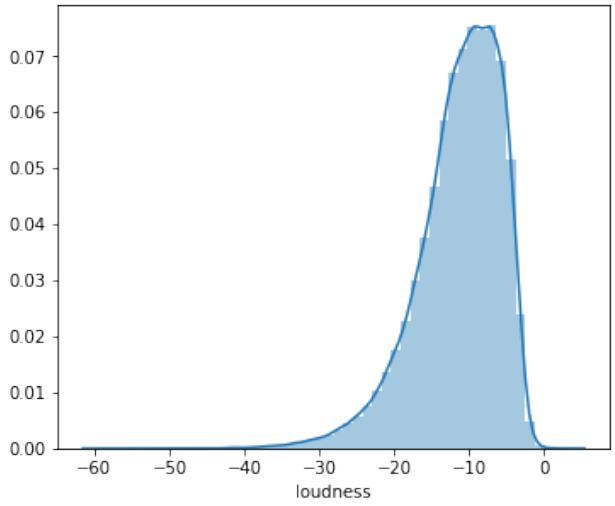
0.07
0.06
0.05
0.04
0.03
0.02
0.01
0.00
−60
−50
−40
−30
−20
−10
0
loudness

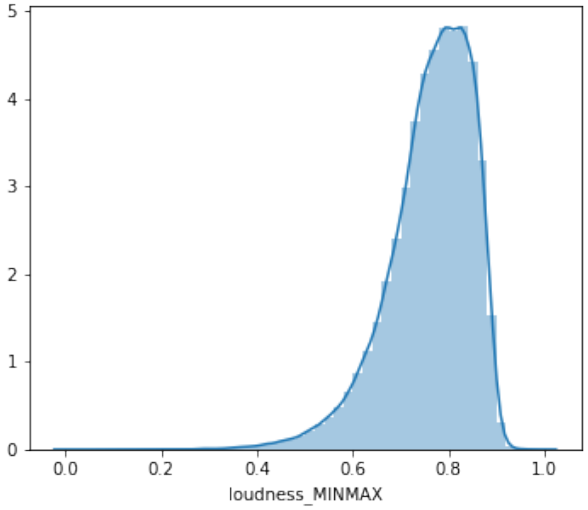
5
4
3
2
1
0
0.0
0.2
0.4
0.6
0.8
1.0
loudness_MINMAX

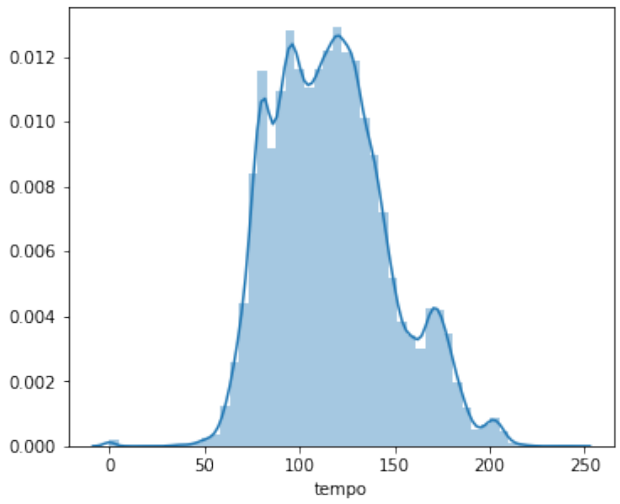
0.012
0.010
0.008
0.006
0.004
0.002
0.000
0
50
100
150
200
250
tempo

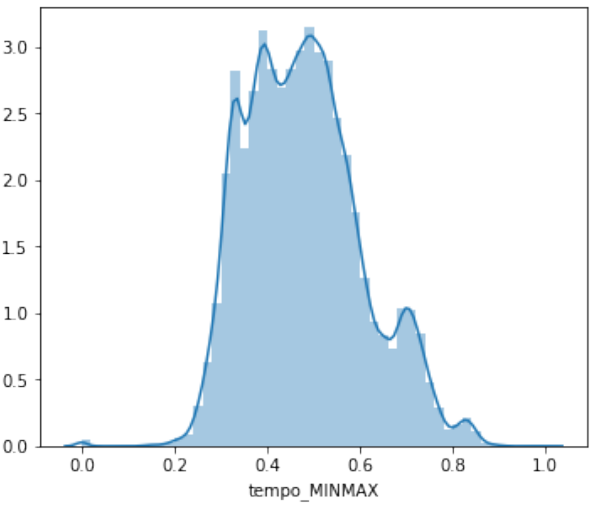
3.0
2.5
2.0
1.5
1.0
0.5
0.0
0.0
0.2
0.4
0.6
0.8
1.0
tempo_MINMAX

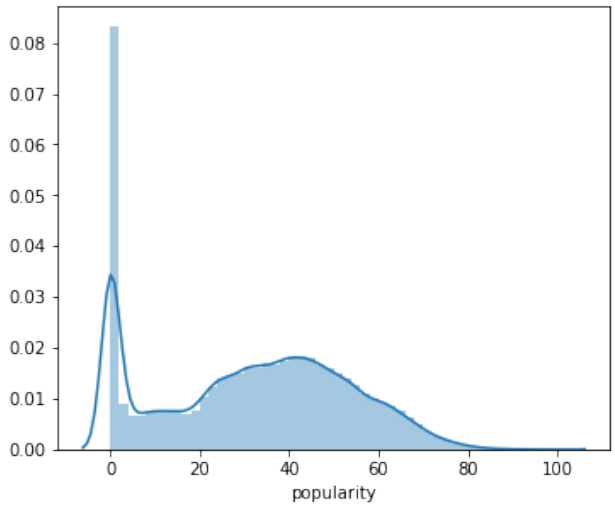

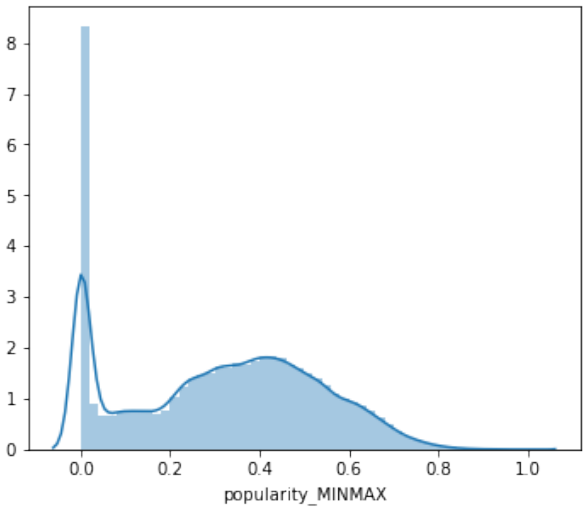

4. Корреляционный анализ данных

[0]:
```
df2 = df1.drop(features_to_scale, axis=1)
df2.head()
```

[0]:

	acousticness	danceability	…	tempo_MINMAX	popularity_MINMAX
0	0.732	0.819	…	0.249645	0.08
1	0.982	0.279	…	0.331655	0.05
2	0.996	0.518	…	0.271296	0.06
3	0.982	0.279	…	0.331655	0.04
4	0.957	0.418	…	0.416505	0.04

[5 rows x 14 columns]

[0]:
```
corr_matrix = df2.corr()
fig, ax = plt.subplots(figsize=(20, 15))
sns.heatmap(corr_matrix, cmap='bwr', annot=True, fmt='.3f',
 ↪linewidths=2, annot_kws={'size': 14}, center=0)
```

[0]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x7f52bf896198>
```

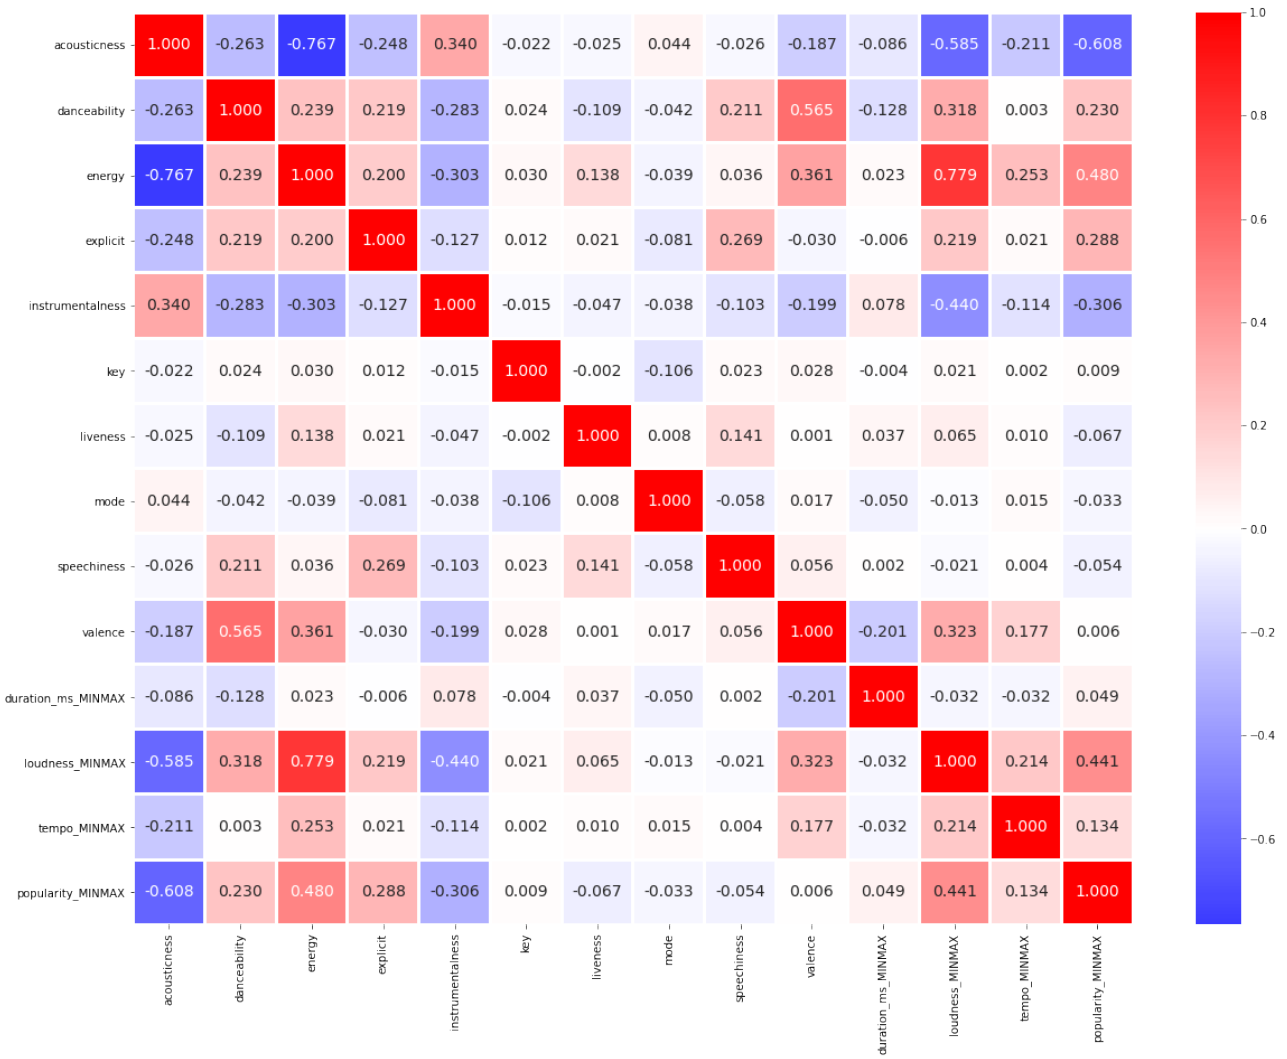

Выводы:

- Наиболее сильно с целевым признаком `popularity_MINMAX` коррелируют признаки `acousticness`, `energy` и `loudness_MINMAX`. Однако, два последних признака обладают очень похожими корреляционными свойствами, и, следовательно, сильно коррелириуют друг с другом. Более того, они так же сильно коррелируют с признаком `acousticness`. Ввиду этого, следует пренебречь одним из них, в данном случае - признаком `energy`.
- Признак `valence` почти не коррелирует с целевым (он сильнее коррелирует с большинством входных признаков), так что его можно смело исключать из модели.

[0]:
```
df3 = df2.drop(["valence", "energy"], axis=1)
```

5. Выбор метрик оценки качества моделей

5.1. Метрика MAE (Mean Absolute Error)

$$\mathrm{MAE}(y, \hat{y}) = \frac{1}{n_{\text{samples}}} \sum_{i=0}^{n_{\text{samples}}-1} |y_i - \hat{y}_i| .$$

Чем ближе к нулю, тем модель лучше себя показывает.

5.2. Метрика MSE (Mean Squared Error)

$$\text{MSE}(y, \hat{y}) = \frac{1}{n_{\text{samples}}} \sum_{i=0}^{n_{\text{samples}}-1} (y_i - \hat{y}_i)^2.$$

5.3. Метрика Explained Variance

Метрика оценивает пропорцию, с которой модель учитывает истинную дисперсию целевого признака. Считается по формуле:

$$explained\_variance(y, \hat{y}) = 1 - \frac{Var\{y - \hat{y}\}}{Var\{y\}}$$

Наилучший показатель равен 1.

5.4. Метрика R^2

$$R^2(y, \hat{y}) = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2},$$

где

$$\bar{y} = \frac{1}{n}\sum_{i=1}^{n} y_i$$

и

$$\sum_{i=1}^{n}(y_i - \hat{y}_i)^2 = \sum_{i=1}^{n} \epsilon_i^2$$

[0]:
```
class MetricLogger:

    def __init__(self):
        self.df = pd.DataFrame(
            {'metric': pd.Series([], dtype='str'),
            'alg': pd.Series([], dtype='str'),
            'value': pd.Series([], dtype='float')})

    def add(self, metric, alg, value):
        """
        Добавление значения
        """
        # Удаление значения если оно уже было ранее добавлено
        self.df.drop(self.df[(self.df['metric']==metric)&(self.
↪df['alg']==alg)].index, inplace = True)
        # Добавление нового значения
        temp = [{'metric':metric, 'alg':alg, 'value':value}]
        self.df = self.df.append(temp, ignore_index=True)

    def get_data_for_metric(self, metric, ascending=True):
        """
```

```
        Формирование данных с фильтром по метрике
        """
        temp_data = self.df[self.df['metric']==metric]
        temp_data_2 = temp_data.sort_values(by='value',
↪ascending=ascending)
        return temp_data_2['alg'].values, temp_data_2['value'].values

    def plot(self, str_header, metric, ascending=True, figsize=(5, 5)):
        """
        Вывод графика
        """
        array_labels, array_metric = self.get_data_for_metric(metric,
↪ascending)
        fig, ax1 = plt.subplots(figsize=figsize)
        pos = np.arange(len(array_metric))
        rects = ax1.barh(pos, array_metric,
                         align='center',
                         height=0.5,
                         tick_label=array_labels)
        ax1.set_title(str_header)
        for a,b in zip(pos, array_metric):
            plt.text(0.5, a-0.05, str(round(b,3)), color='white')
        plt.show()
```

6. Выбор моделей для решения задачи регрессии

- Линейная регрессия
- Машина опорных векторов
- Решающее дерево
- Случайный лес
- Градиентный бустинг

7. Формирование обучающей и тестовой выборок из исходных данных

Для разделения датасета на обучающую и тестовую выборку воспользуемся методом `sklearn.model_selection.train_test_split()`.

[0]:
```
X = df3.drop("popularity_MINMAX", axis=1)
Y = df3["popularity_MINMAX"]
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, Y,
↪random_state=42)
```

[0]:
```
print(X_train.shape, X_test.shape, y_train.shape, y_test.shape)
```

```
(126444, 11) (42148, 11) (126444,) (42148,)
```

8. Baseline модели

[0]:
```
from sklearn.linear_model import LinearRegression
from sklearn.svm import LinearSVR
from sklearn.tree import DecisionTreeRegressor
from sklearn.ensemble import RandomForestRegressor,
 ↪GradientBoostingRegressor
```

[0]:
```
models = {
    "LinR": LinearRegression(),
    "LinSVR": LinearSVR(),
    'Tree': DecisionTreeRegressor(),
    'RF': RandomForestRegressor(n_estimators=10),
    'GB': GradientBoostingRegressor(n_estimators=10),
}
```

[0]:
```
logger = MetricLogger()
```

[0]:
```
from sklearn.metrics import mean_absolute_error, mean_squared_error,
 ↪explained_variance_score, r2_score

def train_model(name, model, log):
  model.fit(X_train, y_train)
  y_pred = model.predict(X_test)

  mae = mean_absolute_error(y_test, y_pred)
  mse = mean_squared_error(y_test, y_pred)
  ev = explained_variance_score(y_test, y_pred)
  r2 = r2_score(y_test, y_pred)

  log.add('MAE', name, mae)
  log.add('MSE', name, mse)
  log.add('EV', name, ev)
  log.add('R2', name, r2)

  print("================================================")
  print(model)
  print()
  print('MAE={}, MSE={}, EV={}, R2={}'.format(
        round(mae, 3), round(mse, 3), round(ev, 3), round(r2, 3)))
  print("================================================")
```

[0]:
```
%%time
for name, model in models.items():
  train_model(name, model, logger)
```

```
================================================
LinearRegression(copy_X=True, fit_intercept=True, n_jobs=None,
 ↪normalize=False)
```

```
MAE=0.131, MSE=0.026, EV=0.427, R2=0.427
================================================

/usr/local/lib/python3.6/dist-packages/sklearn/svm/_base.py:947:
ConvergenceWarning: Liblinear failed to converge, increase the number of
iterations.
  "the number of iterations.", ConvergenceWarning)

================================================
LinearSVR(C=1.0, dual=True, epsilon=0.0, fit_intercept=True,
          intercept_scaling=1.0, loss='epsilon_insensitive',
 ↪max_iter=1000,
          random_state=None, tol=0.0001, verbose=0)

MAE=0.129, MSE=0.029, EV=0.404, R2=0.363
================================================
================================================
DecisionTreeRegressor(ccp_alpha=0.0, criterion='mse', max_depth=None,
                      max_features=None, max_leaf_nodes=None,
                      min_impurity_decrease=0.0, min_impurity_split=None,
                      min_samples_leaf=1, min_samples_split=2,
                      min_weight_fraction_leaf=0.0, presort='deprecated',
                      random_state=None, splitter='best')

MAE=0.144, MSE=0.039, EV=0.15, R2=0.15
================================================
================================================
RandomForestRegressor(bootstrap=True, ccp_alpha=0.0, criterion='mse',
                      max_depth=None, max_features='auto',
 ↪max_leaf_nodes=None,
                      max_samples=None, min_impurity_decrease=0.0,
                      min_impurity_split=None, min_samples_leaf=1,
                      min_samples_split=2, min_weight_fraction_leaf=0.0,
                      n_estimators=10, n_jobs=None, oob_score=False,
                      random_state=None, verbose=0, warm_start=False)

MAE=0.11, MSE=0.021, EV=0.539, R2=0.539
================================================
================================================
GradientBoostingRegressor(alpha=0.9, ccp_alpha=0.0,
 ↪criterion='friedman_mse',
                          init=None, learning_rate=0.1, loss='ls',
 ↪max_depth=3,
                          max_features=None, max_leaf_nodes=None,
                          min_impurity_decrease=0.0,
 ↪min_impurity_split=None,
                          min_samples_leaf=1, min_samples_split=2,
                          min_weight_fraction_leaf=0.0, n_estimators=10,
                          n_iter_no_change=None, presort='deprecated',
                          random_state=None, subsample=1.0, tol=0.0001,
```

```
                                validation_fraction=0.1, verbose=0,
 ↪warm_start=False)

MAE=0.133, MSE=0.026, EV=0.427, R2=0.427
==================================================
```

9. Подбор гиперпараметра для ансамблевой модели случайного леса с использованием кросс-валидации

[0]:
```
estimators_range = np.array(range(10, 31, 10))
parameters = [{"n_estimators": estimators_range}]
```

[0]:
```
%%time
from sklearn.model_selection import GridSearchCV
regr_gs = GridSearchCV(RandomForestRegressor(), parameters, cv=5,
 ↪scoring='neg_mean_squared_error')
regr_gs.fit(X_train, y_train)
```

```
CPU times: user 6min 8s, sys: 295 ms, total: 6min 8s
Wall time: 6min 9s
```

[0]:
```
plt.plot(estimators_range, regr_gs.cv_results_['mean_test_score'])
```

[0]:
```
[<matplotlib.lines.Line2D at 0x7f52bed938d0>]
```

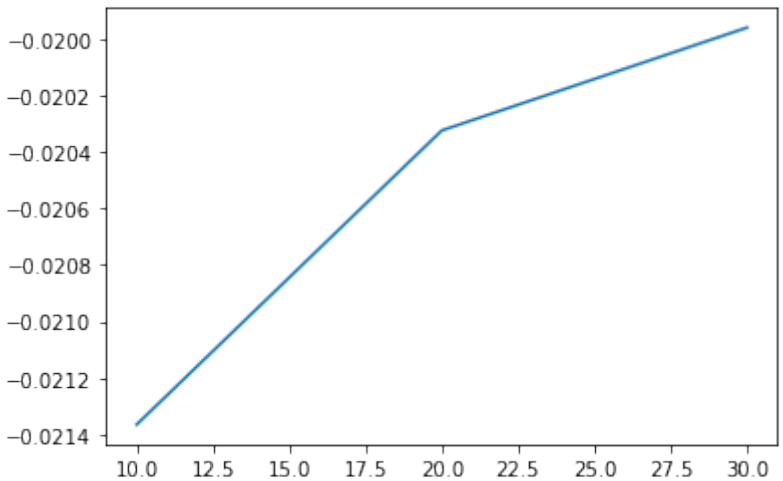

10. Случайный лес с подобранным гиперпараметром

[0]:
```
train_model("RF_30", regr_gs.best_estimator_, logger)
```

```
================================================
RandomForestRegressor(bootstrap=True, ccp_alpha=0.0, criterion='mse',
                      max_depth=None, max_features='auto',
 ↪max_leaf_nodes=None,
                      max_samples=None, min_impurity_decrease=0.0,
                      min_impurity_split=None, min_samples_leaf=1,
                      min_samples_split=2, min_weight_fraction_leaf=0.0,
                      n_estimators=30, n_jobs=None, oob_score=False,
                      random_state=None, verbose=0, warm_start=False)

MAE=0.107, MSE=0.02, EV=0.567, R2=0.567
================================================
```

11. Визуализация оценок моделей

[0]:
```
logger.plot('Метрика: ' + 'MAE', 'MAE', ascending=False)
```

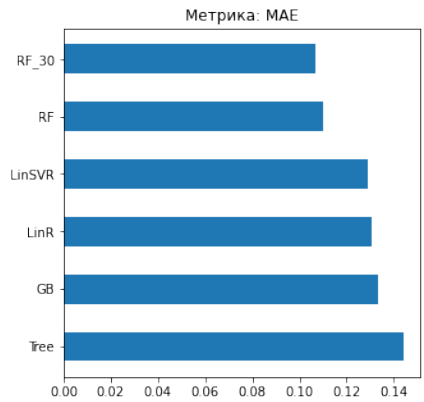

[0]:
```
logger.plot('Метрика: ' + 'MSE', 'MSE', ascending=False)
```

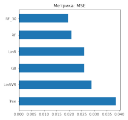

[0]:
```
logger.plot('Метрика: ' + 'EV', 'EV', ascending=True)
```

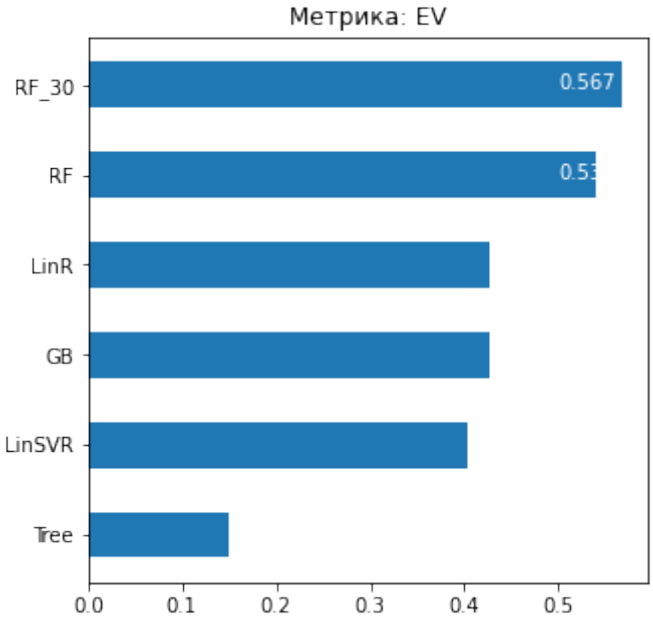

[0]:
```
logger.plot('Метрика: ' + 'R2', 'R2', ascending=True)
```

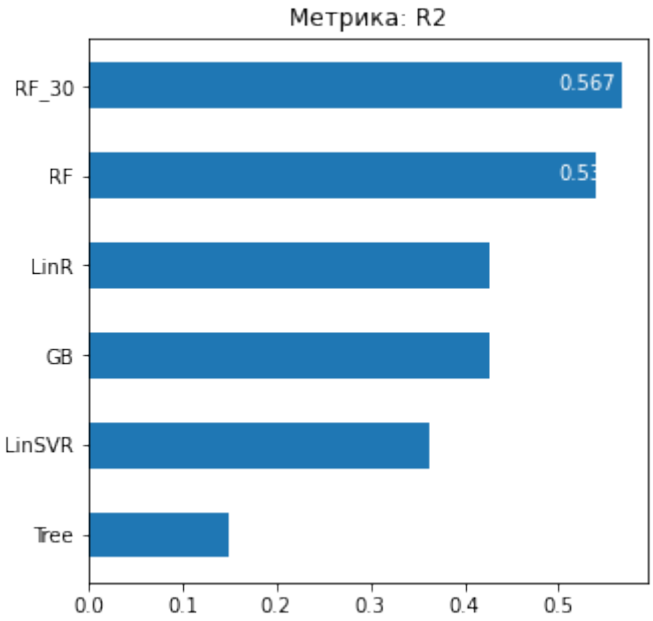

12. Вывод

Наилучшим образом себя показали ансамблевые модели на основе случайного леса. Кросс-валидирующий подбор гиперпараметра `n_estimators` позволил в некоторой степени улучшить работу такой модели.